

指導教員（主査）：山本祐輔 講師

副査：XXX 教授

2018 年度 静岡大学情報学部 卒業論文

XXX に関する研究

— サブタイトル —

静岡大学 情報学部 IS プログラム 所属

学籍番号 XXXXX

静岡 花子

2025 年 12 月 26 日

概要

これはアブストラクトです. 300 字程度でまとめてください.

目次

第 1 章	LaTeX の使い方	5
1.1	LaTeX 環境	5
1.2	見出し	7
1.3	段落	7
1.4	書体	7
1.5	文字装飾	7
1.6	箇条書き	8
1.7	図	8
1.8	表	10
第 2 章	はじめに	12
第 3 章	関連研究	13
第 4 章	提案内容（このセクション名は内容に応じて変更）	15
4.1	方策再利用の基本枠組み	15
4.2	方策選択アルゴリズムの拡張（3 手法の比較）	16
4.3	報酬設計の変更（2 条件での検証）	16
第 5 章	評価実験	18
5.1	実験環境	18
5.2	比較手法	18
5.3	報酬設計	19
5.4	評価指標	19
5.5	実験手順	19

第 6 章	結果	21
6.1	報酬設計 1（ゴール到達報酬のみ）の結果	21
6.2	報酬設計 2（ステップ負報酬＋壁衝突ペナルティ）の結果	22
6.3	まとめ	22
第 7 章	考察	24
7.1	方策選択手法による性能差	24
7.2	報酬設計の変更による影響	25
7.3	限界と今後の課題	25
7.4	まとめ	25
第 8 章	おわりに	27
参考文献		28

図目次

1.1	図のキャプション	9
6.1	報酬設計 1 における学習曲線 (Task 1)	23

表目次

1.1	被験者の割り当て.	11
-----	-------------------	----

第 1 章

LaTeX の使い方

本章では LaTeX の使い方をちょっとだけ解説します。LaTeX は内容とスタイル（見た目）を切り分けて文書を編集することができるソフトウェアです。コマンドを駆使して、美しい文書を作成することができます。

LaTeX の使い方については様々な書籍，ウェブサイトが解説を行っています。詳しい使い方についてはそちらを参考にしてください。

1.1 LaTeX 環境

1.1.1 Overleaf

環境構築が嫌いな人，あるいは楽をしたい人は OverLeaf を使いましょう。OverLeaf はオンライン上で LaTeX を執筆できる環境です。自分の PC/Mac の環境を汚さない，環境構築に苦勞しないというメリットがあります。一方，インターネットに接続していないと執筆作業ができないというデメリットがあります。

Overleaf を使うと決めたら，OverLeaf^{*1}のサイトに行きましょう。そして，トップページの右上にある「登録する」をクリックしてアカウントを作成します。アカウントの作成は Google アカウントを利用すると楽です。研究室や大学で発行された Google アカウントも使用可能です。

アカウントを作成したら，早速 DEIM2019・卒論用のプロジェクトを作成しましょう。まず，GitHub のウェブサイト^{*2}から山本が作成した DEIM2019/卒論用フォーマットの

^{*1} <https://ja.overleaf.com>

^{*2} <https://github.com/ymmt3-lab/DEIM-and-Thesis/archive/master.zip>

ZIP ファイルをダウンロードしておきます。この際、ファイルは解凍せずに ZIP ファイルのままにしておいてください。もし、解凍してしまった場合はフォルダを ZIP 圧縮してください。次に Overleaf にログインし、ログイン後の画面に左上に表示されている「新規プロジェクト」の中の「プロジェクトのアップロード」をクリックします。そして、先ほどダウンロードした ZIP ファイルをアップロードします。これで DEIM2019/卒論用の執筆プロジェクトが作成されます。プロジェクトを作成したら、LaTeX の編集画面が表示されます。画面左側にファイルブラウザ、およびその中に様々なファイルがあるのが確認できます。

最後に Overleaf で日本語 PDF を作成するための設定をします。画面左上のメニューをクリックしてください。表示されたメニューの中に「コンパイラ」という項目があるので、これを「LaTeX」に設定します。さらに、「主要文書」を「paper.tex」に設定します。もう一手間かけましょう。画面中央最上部にプロジェクト名が表示されています。アップロードした ZIP ファイル名が master.zip なら「master」となっているはずです。これを「DEIM2019-卒論」のように、わかりやすいプロジェクト名に変更しておいてください。以上で執筆環境の設定は完了です。

では早速 Overleaf で PDF 文書を作成してみましょう。ファイルブラウザから DEIM フォルダの中にある paper.tex を選びます。クリックすると、paper.tex の中身が画面に表示されます。この状態で、画面中央あたりにある「再編集」という緑色のボタンをクリックしましょう。しばらくすると、LaTeX ファイルがコンパイルされ、PDF が表示されます。

論文執筆環境が整いましたので、DEIM2019/卒論投稿に向けて原稿を書き進めましょう。paper.tex ファイルは論文のタイトルや著者名、および論文を構成する各章のコンテンツファイルへのリンクを記しただけのファイルです。肝心の中身は contents/text フォルダの中にあるファイルに書くように設定しています。執筆対象となる章に対応するファイルをクリックし、中身を完成させてください。

1.1.2 ローカル環境

環境構築に抵抗がない人は自分の PC/Mac 上に LaTeX 環境を構築しましょう。世の中には様々な LaTeX 環境があります。最も有名なのは TeXLive です。こだわりがなければ TeXLive のウェブサイトからソフトウェアをダウンロードしインストールしましょう。インストールが完了したら TeXWorks というアプリケーションを起動してください。このアプリケーションを使うことで、LaTeX で文書を作成することができます。

1.2 見出し

文章を構造化するには、内容を章別、項別に整理することが重要です。例えばこの文書では「第 1 章 LaTeX の使い方」が章に対応し、「1.1 LaTeX 環境」が節に対応します。LaTeX では `section` コマンドを用いることで章見出しを、`subsection` コマンドを用いることで節見出しを作成することができます。実際の使い方については、`contents/text` ディレクトリにある `latex.tex` ファイルの中身を覗いてみてください。本章に対応する LaTeX ソースが確認できます。

1.3 段落

ある文章とある文章を段落で分けたい場合、LaTeX では文章間に空行を入れることで段落を作ることができます。

この節の第 2 段落の LaTeX ソースを確認してください。前段落の文章とこの段落の文章との間に空行が設けられていることが確認できます。

1.4 書体

LaTeX ではコマンドを用いて、文章の特定の箇所の書体を変更することができます。例えばこの文書は地の文のデフォルト書体として明朝体が定義されていますが、`gt` コマンドを用いることで、次の 1 文をゴシック体に変更することができます。**このように書体がゴシック体になりました。ゴシック体以外にも、Roman family, Typewriter family, SMALL CAPS SHAPE, など、様々な書体を利用することができます。こういった書体がどのコマンドで利用できるかは、「LaTeX コマンド集 - 書体」等のウェブページで確認してください。**

1.5 文字装飾

文字を太字にするには `bf` コマンドを用います。文字に下線を引くには `underline` コマンドを用います。これらのコマンドを使うことで、このように**太字**や下線で文字を修飾することができます。実際の使い方については、`contents/text` ディレクトリにある `latex.tex` ファイルの中身を覗いてみてください。

1.6 箇条書き

箇条書きは番号ありと番号なしの書き方ができます。番号なしの箇条書きは,

- 箇条書き 1
- 箇条書き 2
- 箇条書き 3

のような形式になります。上記番号なし箇条書きを行うには、以下コードを書きます。

```
\begin{itemize}
  \item 箇条書き 1
  \item 箇条書き 2
  \item 箇条書き 3
\end{itemize}
```

番号ありの箇条書きは,

1. 箇条書き a
2. 箇条書き b
3. 箇条書き c

のような形式になります。上記番号あり箇条書きを行うには、以下コードを書きます。

```
\begin{itemize}
  \item 箇条書き 1
  \item 箇条書き 2
  \item 箇条書き 3
\end{itemize}
```

1.7 図

図を論文に掲載するには `figure` コマンドおよび `includegraphics` コマンドを用います。具体的には以下のようなコマンドを書きます。



図 1.1 図のキャプション

```
\begin{figure*}[tb]
  \begin{center}
    \includegraphics[width=13.5cm, clip]{../contents/figure/example.eps}
    \caption{図のキャプション}
    \label{fig:example}
  \end{center}
\end{figure*}
```

上記コマンドを使うことで、本節で掲載している図を掲載できます。なお、`figure` コマンドの代わりに `figure*` コマンドを用いると、論文フォーマットが 2 カラムの場合、2 カラム分のスペースを用いて図を掲載します。

LaTeX では図の配置位置は大まかには指定できますが、ほぼ自動的に行われます。指定できる位置としては主に「ページ上部 (t)」「ページ下部 (b)」「図コマンドを挿入した場所 (h)」の 3 種類ありますが、学術論文ではページ上部もしくはページ下部のどちらかに図を配置することが一般的です。図の配置位置は `figure` コマンドのオプションで指定できます。上の例では図の配置位置のページ上部（優先順位 1）、ページ下部（優先順位 2）を指定します。

図を掲載するときは図にキャプションを添える必要があります。キャプションは `caption` コマンドを用います。

掲載した図（および表）は図表番号を使って論文中で参照します。論文の修正過程で図表の掲載順を変えた場合、それに応じて本文中の図表参照番号を変更する必要があります

(例：図 1.1)。それを逐一手作業で行っていると面倒ですし，誤植の可能性も高まります。LaTeX ではこの問題を解決するために `label` コマンドを提供しています。積極的に使いましょう。

1.8 表

表を論文に掲載するには `figure` コマンドおよび `table` コマンドを用います。具体的には以下のようなコマンドを書きます。

```
\begin{table}[tb]
  \begin{center}
    \caption{被験者の割り当て}
    \scalebox{1.00}{
      \begin{tabular}{c c c} \hline
        \toprule
          & \multicolumn{2}{c}{\textbf{性別}} & \\
          & \cmidrule(lr){2-3}
          \textbf{UI} & \textbf{男性} & \textbf{女性} \\
          & \midrule
          Type A & 29 & 31 \\
          Type B & 26 & 32 \\
          & \bottomrule
        \end{tabular}
      }
    \label{table:example}
  \end{center}
\end{table}
```

表の配置位置は `figure` コマンドのオプションで指定できます。上の例では表の配置位置のページ上部（優先順位 1），ページ下部（優先順位 2）を指定します。

表 1.1 被験者の割り当て.

UI	性別	
	男性	女性
Type A	29	31
Type B	26	32

第2章

はじめに

近年、強化学習を実運用へ適用するためには、環境が変化しても短時間で性能を回復・向上できる適応性が重要である。強化学習は、エージェントが試行錯誤を通じて最適な行動方策を獲得する枠組みであり、ゲームやロボティクスに加え、物流・製造計画など多様な領域での活用が期待されている。一方で、反復的な探索と学習には多大な試行回数と計算時間を要し、実環境では学習効率の低さが主要な課題となる。例えば倉庫の入出庫スケジュール最適化や工場のジョブショップスケジューリングでは、設備配置や需要が変化するたびにゼロから学習し直すことは現実的でない場合が多い。

この課題に対する有力なアプローチとして転移学習がある。転移学習では、変化前の環境（ソース）で獲得した知識を、新しい環境（ターゲット）の学習に再利用することで、学習初期の性能向上や総学習時間の短縮が期待できる。とりわけ、方策や価値関数の再利用は、環境構造が類似する場合に効果的であり、実運用における迅速な再最適化に資する。しかし、ソース知識をどの程度信頼して利用するかは容易ではなく、不適切な再利用はターゲット適応を阻害する。加えて、行動選択（探索戦略）の設計は学習効率を左右する重要因子であるにもかかわらず、特定の方策選択に依存した検討に留まることが多い。

本研究では、転移学習の枠組みにおける方策選択手法の影響を体系的に評価することを目的とする。具体的には、既存研究で用いられているボルツマン選択に加え、 ϵ -greedy および UCB を導入し、3種類のバンディットアルゴリズムに基づく方策選択を同一条件下で比較実験する。さらに、報酬設計の違いが比較結果に与える影響にも着目し、従来の報酬に加えて、各ステップでのマイナス報酬および壁衝突時のペナルティを導入した報酬設計を用いた場合についても同様の検証を行う。これにより、探索と活用のバランスが異なる方策選択が、報酬構造の変化に対してどのように挙動を変えるのかを明らかにし、実運用を見据えた転移強化学習の設計指針を得ることを目指す。

第 3 章

関連研究

強化学習における学習効率の改善を目的として、ソース環境で得た知識をターゲット環境へ再利用する転移学習が広く研究されている。転移の形態としては、価値関数（Q 値）の初期化、方策の転用、特徴表現の共有などが挙げられる。特に、過去に学習した方策を学習中の探索へ組み込む「方策再利用」は、環境構造が類似する場合に学習初期の性能を押し上げる一方、類似度が低い場合には負の転移が生じうるため、再利用の制御が重要となる。

Fernández と Veloso は、複数の過去方策を保持した方策ライブラリ（Policy Library）から、ターゲット環境における学習を支援するために過去方策を確率的に再利用する枠組みを提案した [?]. この枠組みでは、方策ライブラリ $\mathcal{L} = \{\Pi_1, \Pi_2, \dots, \Pi_n\}$ と、ターゲットで学習中の新方策 Π_Ω を併せて候補とし、エピソードごとに 1 つの方策を選択して実行する。各方策 Π_i には、その方策を選択した際の有効性を表す指標 W_i （Reuse Gain）を保持し、得られたリターンに基づいて更新する。

方策選択は、 W_i を用いてボルツマン分布（softmax）で確率的に行う。文献 [?] では、最も大きな W を持つ方策の指標として

$$j^* = \arg \max_{i=1, \dots, n} W_i \quad (3)$$

を定義し、候補方策 Π_j が選択される確率を

$$P(\Pi_j) = \frac{\exp(\tau W_j)}{\sum_{p=0}^n \exp(\tau W_p)} \quad (4)$$

で与える。ここで $p = 0$ は新方策（文献では Π_Ω ）に対応し、 W_0 は W_Ω とする。また、選択された過去方策に追従しつつ探索も行うために、確率 ψ で選択方策の推奨行動を採用し、確率 $1 - \psi$ で探索行動を採用するような π -reuse に相当する実行戦略が導入され

ている．このように，どの過去方策が有効か事前に分からない状況でも，リターンに基づいて選択確率を更新することで，方策再利用の効果を得ることを狙っている．

一方，強化学習の性能を左右する要因として，探索と活用のトレードオフを制御する方策選択（行動選択）手法がある．代表的な手法として， ϵ -greedy，ボルツマン選択（softmax），UCB（Upper Confidence Bound）などが知られている． ϵ -greedy は確率 ϵ でランダム行動を選択し，それ以外では推定価値が最大の行動（あるいは方策）を選択する単純な方法である．ボルツマン選択は推定価値の差に応じた確率分布からサンプリングすることで，滑らかな探索制御を可能にする．UCB は推定価値に加えて不確実性（試行回数の少なさ）を上乗せし，上界を最大化する対象を選ぶことで理論的に探索を促進する．文献 [?] では方策ライブラリからの方策選択をボルツマン分布で行っているが，方策選択は多腕バンディットとして捉えることができるため，ボルツマン以外のバンディットアルゴリズム（ ϵ -greedy や UCB 等）を適用した場合に挙動や学習効率がどのように変化するかを比較する意義がある．

さらに，報酬設計は学習の安定性や方策の性質に大きく影響することが知られている．迷路のような経路探索問題において，ゴール到達報酬中心の設計に対し，各ステップの負報酬（ステップコスト）を導入すると最短経路志向が強まりやすい．また，壁衝突に対するペナルティを導入することで無効行動を抑制できる可能性がある一方，過度なペナルティは探索を萎縮させ，学習を遅らせる可能性もある．したがって，探索戦略・バンディット手法の比較は単一の報酬設計に限定せず，報酬構造を変えた場合にも優劣関係が維持されるか（あるいは逆転するか）を検証することが重要である．

以上の先行研究を踏まえ，本研究は方策再利用（PRQ-Learning）の枠組みにおける「方策選択」に着目し，文献 [?] で用いられているボルツマン選択に加えて ϵ -greedy および UCB を導入し，どのバンディットアルゴリズムが有効かを比較・考察する．さらに，ゴール到達報酬のみの設計に加え，ステップ負報酬と壁衝突ペナルティを導入した報酬設計でも同様の比較を行い，報酬構造の変更が各手法の挙動と性能差に与える影響を明らかにする．

第 4 章

提案内容（このセクション名は内容に応じて変更）

本研究の目的は、方策再利用（Policy Reuse）の枠組みにおいて「どの方策を使って 1 エピソードを進めるか」という方策選択を、ボルツマン選択に限定せず、複数のバンディットアルゴリズムで置き換えて比較可能にすることである。さらに、その優劣が報酬設計の変更によってどのように変化するかを検証できるよう、報酬関数を 2 種類用意する。

4.1 方策再利用の基本枠組み

ソース環境で得られた方策を格納した方策集合（Policy Library）を

$$\mathcal{L} = \{\pi_1, \pi_2, \dots, \pi_K\} \quad (4.1)$$

とし、ターゲット環境で学習中の方策（Q 学習で暗黙に定義される方策）を π_{new} とする。各エピソードの開始時に、 $\mathcal{L} \cup \{\pi_{\text{new}}\}$ の中から 1 つの方策を選択し、そのエピソード中は選択された方策を参照しながら行動を決定する。エピソード終了後には、得られた累積報酬（リターン）を用いて「どの方策が有効だったか」の推定値を更新し、次エピソード以降の方策選択に反映する。

また、エピソード内の行動決定は、選択した方策の提案行動に従う確率（再利用率）を ψ とし、確率 ψ で選択方策の行動を採用、確率 $1 - \psi$ で探索（または学習中の方策の行動）を採用する形で統一する。これにより、本研究では「方策選択アルゴリズムの差」が結果に与える影響を明確に比較できる。

4.2 方策選択アルゴリズムの拡張（3 手法の比較）

既存研究では、方策集合からの選択をボルツマン分布に基づいて行う設定が採られている。本研究では、この方策選択を多腕バンディット問題として捉え、以下の 3 手法を同一枠組みで実装し比較する。ここで、各方策 π_i には推定価値 V_i （例：過去にその方策を選んだエピソードのリターン平均）と選択回数 N_i を保持し、エピソード終了ごとに更新する。

1. ボルツマン選択 (Softmax)

推定価値 V_i に応じて確率的に方策を選ぶ。温度パラメータにより探索の強さを調整できる。価値差が小さいときも複数方策を試しやすい一方、温度設定に挙動が依存しやすい。

2. ϵ -greedy

確率 $1 - \epsilon$ で現在もっとも推定価値が高い方策を選択し、確率 ϵ でランダムに方策を選ぶ。実装が単純で解釈もしやすいが、探索の仕方が一様であり、不確実性を直接扱わない。

3. UCB (Upper Confidence Bound)

推定価値に「未試行の方策を試すべき度合い」を加点して方策を選ぶ。一般に時刻（エピソード） t において

$$\pi = \arg \max_i \left(V_i + c \sqrt{\frac{\log t}{N_i}} \right) \quad (4.2)$$

のように、試行回数が少ない方策ほど上界が大きくなるため、探索を理論的に促進できる。一方でパラメータ c により探索の強さが変化し、タスクや報酬設計により最適値が異なる可能性がある。

このように、確率的探索（ボルツマン）、単純なランダム探索（ ϵ -greedy）、不確実性を明示的に扱う探索（UCB）を揃えることで、方策再利用における「方策の選び方」の影響を多面的に評価できる。

4.3 報酬設計の変更（2 条件での検証）

方策選択の優劣は、環境の報酬構造によって変化する。そこで本研究では、以下の 2 種類の報酬設計を用意し、同一の比較を行う。

1. 既存研究に準じた報酬設計

ゴール到達を主に評価する設計（例：到達報酬中心）を用い，まず既存設定に近い条件で3手法の差を確認する．

2. 罰則を追加した報酬設計（本研究の拡張）

各ステップに負の報酬（ステップコスト）を与え，さらに壁衝突に対して追加のペナルティを与える．これにより無駄な行動や回り道を抑制し，最短経路志向を強めることが期待される一方，ペナルティの導入は探索の性質を変化させ，方策選択手法間の優劣関係にも影響しうる．本条件での比較により，報酬の形が変わると，どのバンディット手法が有利になるかを検証する．

第 5 章

評価実験

本章では，提案する方策選択手法（ボルツマン選択， ε -greedy，UCB）の比較評価を行う．評価は方策再利用の枠組みの下で実施し，さらに報酬設計を 2 種類用意することで，報酬構造の違いが各手法の性能に与える影響も検証する．

5.1 実験環境

本研究では，格子状の迷路環境を用いて評価を行う．エージェントは各状態において上下左右のいずれかの行動を選択し，壁への衝突が発生する場合は状態が遷移しない（または同一状態に留まる）ものとする．各エピソードは，スタート状態から開始し，ゴール状態に到達した時点で終了する．

転移学習の設定として，ソース環境であらかじめ学習した方策を方策ライブラリ $\mathcal{L}$ に格納し，ターゲット環境での学習時に $\mathcal{L} \cup \{\pi_{\text{new}}\}$ の中から 1 つを選択してエピソードを実行する．なお，環境をドメイン $D = \langle S, A, T \rangle$ とタスク $\Omega = \langle D, R_{\Omega} \rangle$ に分けて定義する．本研究ではソースとターゲットは同一ドメイン D を共有し，ゴール設定の違いをタスク差として扱う．

5.2 比較手法

方策選択（エピソードごとに採用する方策の選択）として，以下の 3 手法を比較する．

1. ボルツマン選択 (Softmax)
2. ε -greedy
3. UCB (Upper Confidence Bound)

いずれの手法においても、各方策 π_i に対して推定価値 V_i と選択回数 N_i を保持し、エピソード終了後にそのエピソードのリターンに基づいて V_i を更新する。また、エピソード内の行動決定は再利用率 ψ を用いた統一的な π -reuse の構成とし、方策選択手法の差が比較に反映されるようにする。

5.3 報酬設計

報酬設計は以下の 2 条件を用意し、それぞれの条件で 3 手法の比較を行う。

1. 既存研究に準じた報酬設計

ゴール到達を主に評価する設計（例：到達報酬中心）を用いる。

2. 罰則を追加した報酬設計

各ステップに負の報酬（ステップコスト）を与え、さらに壁衝突に追加ペナルティを与える。これにより無効行動の抑制および最短経路志向の変化を誘発し、方策選択手法間の挙動差を検証する。

5.4 評価指標

参考文献に倣い、各 trial (episode) k で得られる割引累積報酬を W_k とし、trial t までの平均利得を

$$\bar{W}_t = \frac{1}{t} \sum_{k=1}^t W_k \quad (5.1)$$

として学習曲線を描画する。

5.5 実験手順

実験は以下の手順で行う。

1. ソース環境において Q 学習により方策を学習し、学習済み方策を方策ライブラリ $\mathcal{L}$ に格納する。
2. ターゲット環境において学習を開始し、各エピソード開始時に方策選択手法（ボルツマン選択, ϵ -greedy, UCB）により $\mathcal{L} \cup \{\pi_{\text{new}}\}$ から 1 つの方策を選択する。
3. 選択された方策に基づき π -reuse によりエピソードを実行し、得られたリターンで選択方策の推定価値を更新する。同時に、ターゲット環境における Q 値更新を行

い π_{new} を改善する.

4. 所定のエピソード数だけ学習を行い, 評価指標を記録する.
5. 上記を報酬設計 2 条件それぞれで実施し, 3 手法の結果を比較する.

第 6 章

結果

本章では、報酬設計 1（ゴール到達報酬のみ）および報酬設計 2（ステップ負報酬＋壁衝突ペナルティ）における学習曲線の比較結果を示す。図中のエラーバーは複数試行（runs=5）におけるばらつきを表す。以降の PRQ における方策選択（バンディット）手法は、事前のグリッドサーチにより各条件で良好であったパラメータを用いた。具体的には、報酬設計 1 では Boltzmann ($\tau_0 = 0.0$, $d\tau = 0.05$), ϵ -greedy ($\epsilon_b = 0.05$), UCB ($c = 0.3$), 報酬設計 2 では Boltzmann ($\tau_0 = 0.05$, $d\tau = 0.05$), ϵ -greedy ($\epsilon_b = 0.2$), UCB ($c = 0.1$) を用いた。なお、Baseline は ϵ -greedy による通常の Q 学習である。

6.1 報酬設計 1（ゴール到達報酬のみ）の結果

報酬設計 1 においては、いずれのタスクにおいても PRQ（方策再利用）系列が Baseline を一貫して上回り、学習初期から累積平均利得（cumulative mean gain）がより大きくなる傾向が確認できる。例えば Task 1 (goal=(2,2)) では、3 手法はいずれも Baseline より高い利得を示し、特に UCB が終盤までわずかに高い値を維持した。一方で Boltzmann と ϵ -greedy は近い性能で推移し、差は小さい（図 1 相当）。

Task 5 (goal=(12,12)) では、 ϵ -greedy が学習初期から立ち上がりが速く、終盤まで高い利得を示した。ただし、 ϵ -greedy はエラーバーが比較的大きく、試行間のばらつきが大きいことも確認できる。UCB は他 2 手法よりやや低い曲線となった（図 2 相当）。

Task 12 (goal=(9,1)) および Task 15 (goal=(21,5)) では、UCB と Boltzmann が高い性能を示し、 ϵ -greedy はそれらに比べて明確に低い利得で推移した。特に Task 15 では、UCB が学習初期から大きく優位であり、Boltzmann がそれに続き、 ϵ -greedy は中盤以降に改善するものの差が残った（図 3, 図 4 相当）。以上より、報酬設計 1 では PRQ

により Baseline を大きく上回る改善が得られ、その中でもタスクによって最も有効な方策選択手法が変化することが示唆される（例：Task 5 では ϵ -greedy が優位，Task 12/15 では UCB や Boltzmann が優位）。

6.2 報酬設計 2（ステップ負報酬＋壁衝突ペナルティ）の結果

報酬設計 2 では、ステップ負報酬および壁衝突ペナルティの導入により、累積平均利得が全体として負の領域から推移するタスクが多く見られた。しかしその場合でも、PRQ 系列は Baseline より一貫して高い値（より負が小さい、あるいは 0 に近い）を示し、報酬設計を変更しても方策再利用が学習効率改善に寄与することが確認できる。

Task 1 (goal=(2,2)) では、3 手法の曲線はほぼ重なって推移し、方策選択手法間の差は小さい一方、PRQ 系列は Baseline を大きく上回った（図 5 相当）。Task 5 (goal=(12,12)) では、Boltzmann が最も高い利得を示し、 ϵ -greedy がそれに続いた。UCB は他 2 手法より低い曲線となり、特に終盤で差が残った。

Task 9 (goal=(15,19)) および Task 12 (goal=(9,1)) では、UCB が全体として最も高い利得を示し、Boltzmann がそれに続き、 ϵ -greedy が相対的に低い傾向となった（図 7、図 8 相当）。このように報酬設計 2 では、報酬のスケールや負報酬の影響により曲線の絶対値は変化するものの、PRQ 系列の優位性自体は維持され、さらにタスクによっては UCB が安定して高い性能を示す一方、Task 5 のように Boltzmann が優位となるケースも確認された。

6.3 まとめ

2 種類の報酬設計のいずれにおいても、PRQ（方策再利用）系列は Baseline（通常の Q 学習）を一貫して上回り、転移（再利用）による学習効率向上が確認できた。一方で、PRQ 内の方策選択手法（Boltzmann, ϵ -greedy, UCB）の優劣はタスクおよび報酬設計に依存して変化し、単一の手法が常に最良となるわけではないことが示唆された。この依存関係については次章の考察で詳述する。




図 6.1 報酬設計 1 における学習曲線 (Task 1)

第 7 章

考察

本章では，結果章で得られた学習曲線の傾向について，(i) 方策選択（バンディット）手法の特性，(ii) 報酬設計の変更による影響，(iii) グリッドサーチで選定されたパラメータの意味，の観点から考察する．

7.1 方策選択手法による性能差

報酬設計 1 において，PRQ 系列はいずれのタスクでも Baseline を上回り，方策再利用が学習初期の性能向上に寄与することが確認できた．一方で，PRQ 内の方策選択手法（Boltzmann, ϵ -greedy, UCB）の優劣はタスクに依存して変化した．Task 5 では ϵ -greedy が立ち上がりが高く高い性能を示したが，エラーバーが比較的大きく，試行間のばらつきが大きい傾向も見られた． ϵ -greedy は探索が一様であるため，偶然有効な方策を早期に引き当てた場合には急速に性能が伸びる一方，引き当てのタイミングが遅れる試行では学習が遅れ，分散が大きくなりやすいと解釈できる．

一方，Task 12 や Task 15 では UCB および Boltzmann が優位であり， ϵ -greedy は相対的に低い性能に留まった．UCB は推定価値に不確実性（選択回数の少なさ）を加点することで，未探索の方策を段階的に試す方向へ選択を誘導する．そのため，タスクによって有効な方策が変化しやすい条件や，初期の推定値が不安定な条件では， ϵ -greedy よりも探索が安定し，高い性能に繋がった可能性がある．Boltzmann も確率的に複数方策を試しながら価値差に応じて選択確率を変化させるため，UCB ほどの探索保証はないものの，温度の設定次第で探索と活用のバランスを滑らかに調整でき，タスクによっては UCB に近い挙動を示したと考えられる．

7.2 報酬設計の変更による影響

報酬設計 2 では、ステップ負報酬および壁衝突ペナルティを導入したため、累積平均利得が負の領域から推移するタスクが多く見られた。この変化は「ゴール到達だけでなく、途中の行動コストを明示的に最適化対象へ含めた」ことに対応している。しかし、利得の絶対値が変化しても、PRQ 系列が Baseline を一貫して上回る傾向は維持されており、方策再利用の効果は報酬構造の変更に対して比較的頑健であることが示唆される。

一方で、PRQ 内の 3 手法の関係は報酬設計によって変化した。例えば Task 5 では報酬設計 2 で Boltzmann が最も高い利得を示し、UCB が相対的に低くなった。これは、負報酬を導入したことで短期的なコストの違いが価値推定に反映されやすくなり、価値差に応じて確率的に選択を集中させる Boltzmann が有利に働いた可能性がある。一方、Task 9 や Task 12 では UCB が高い性能を維持しており、ペナルティ導入により探索が難しくなった状況でも、不確実性を考慮した選択が有効なケースが存在することが分かる。このことから、報酬設計は「どの方策選択が有利か」を変えうる要因であり、単一条件で得た結論を一般化するには注意が必要である。

7.3 限界と今後の課題

本研究の比較は、迷路環境および設定した 2 種類の報酬設計に基づくものであり、報酬スケールや迷路構造、方策ライブラリの多様性が変化した場合に同様の傾向が再現されるかは追加検証が必要である。また、本研究ではグリッドサーチによりパラメータを選定したが、実運用を想定するとタスクごとに広範な探索を行うことはコストが高い。今後は、環境の特徴量や学習進行に応じてパラメータを自動調整する手法（適応的温度制御や探索率制御）を導入し、チューニング負荷を低減することが課題となる。さらに、関数近似を用いる大規模状態空間や深層強化学習への拡張、複数のソース環境からの方策選択なども検討対象となる。

7.4 まとめ

以上より、方策再利用による学習効率改善は報酬設計の変更に対して一定の頑健性を示した一方で、PRQ 内の方策選択手法の最適な選択はタスクおよび報酬構造に依存して変化することが確認された。したがって、転移強化学習を実運用へ適用する際には、環境変

化や報酬設計に応じて探索戦略を選択・調整することが重要である。

第 8 章

おわりに

本研究では、環境変化に対して迅速に適応する強化学習の実現に向け、方策再利用 (Policy Reuse) の枠組みにおける方策選択に着目し、既存研究で用いられているボルツマン選択に加えて ϵ -greedy および UCB を導入した比較実験を行った。さらに、報酬設計を 2 種類 (ゴール到達報酬のみ、およびステップ負報酬 + 壁衝突ペナルティ) 用意し、報酬構造の変更が各方策選択手法の挙動と性能差に与える影響も検証した。その結果、いずれの報酬設計においても方策再利用を用いる PRQ 系列は Baseline (通常の Q 学習) を一貫して上回り、転移 (再利用) による学習効率向上が確認できた。一方で、PRQ 内の方策選択手法の優劣はタスクや報酬設計に依存して変化し、単一の手法が常に最良となるわけではないことが示唆された。

今後の課題として、より多様な迷路構造や報酬スケールに対する再現性検証に加え、グリッドサーチに依存しない形で探索パラメータを自動調整する手法の導入が挙げられる。また、本研究は表形式の Q 学習を前提としたが、より大規模な状態空間や実問題への適用を想定すると、関数近似や深層強化学習への拡張が重要となる。加えて、複数のソース環境から得られた方策をライブラリに蓄積する状況では、方策の選択・管理戦略そのものが性能に直結するため、方策集合の構成方法や選択基準の高度化も検討すべきである。これらの検討を通じて、環境変化を伴う実運用場面においても頑健かつ効率的に学習できる転移強化学習手法の確立を目指す。

参考文献

- [1] E. F. Codd, “A Relational Model of Data for Large Shared Data Banks,” Communications of the ACM (CACM), Vol. 13, No. 6, pp. 377–387, 1970.

謝辞

本研究の遂行ならびに論文の作成にあたり，ご指導を賜りました XX 大学 XX 先生に謹んで深謝の意を表します。

本論文をまとめるにあたり，副査として有益な御助言と御教示を賜りました XX 先生に心より感謝の意を表します。

本研究の遂行ならびに論文の作成にあたり御協力いただいた，XX 大学 XX 研究室の皆様へ感謝致します。特に，XX してくれた XX 君に心より感謝致します。

最後に，これまで暖かく見守ってくれた両親に感謝します。

20XX 年 3 月 静岡 花子